





O'REILLY®


Hands-On Large Language Models

Language Understanding
and Generation



Jay Alammar &
Maarten Grootendorst

熬夜書坊




Chapter 9



多模態大型語言模型 (Multimodal LLMs)


Input modality

Output modality




Input Features

Output Prediction



Image



Textual input

What a horrible movie!

Tokens

[CLS]

what

a

horrible

movie

!

[SEP]

ENCODER



Original image



Patched image



Flattened input



Original image



Patched image




Flattened input




Linear projection



Patch embeddings



ENCODER



Sentence

... This is a cat

Multimodal
embedding
model

Sentence
embedding




Image




Image
embedding

CLIP (Contrastive Language-Image Pre-training)

(1) Contrastive pre-training



(2) Create dataset classifier from label text



Image



Caption



"A pixelated image
of a cute cat"



"A puppy playing
in the snow"



"A supercar on the
road with the sunset
in the background"



A puppy playing in the snow

0.33

0.19

0.11

A pixelated image of a cute cat

0.15

0.35

0.09

A supercar on the road with
the sunset in the background

0.08

0.13

0.31


CLIP 應用

- **零樣本分類 (Zero-shot classification)**
 - 我們可以將影像的嵌入向量與其可能類別的描述向量進行比對，藉此找出相似度最高的類別。
- **分群 (Clustering)**
 - 將影像與一系列關鍵字同時進行分群，藉此找出哪些關鍵字隸屬於哪一組影像集合。
- **搜尋 (Search)**
 - 在數以億計的文字或影像中，我們能夠極其快速地檢索出與輸入文字或影像相關聯的內容。
- **生成 (Generation)**
 - 利用多模態嵌入向量來驅動影像的生成（例如：Stable Diffusion）。


Pretrained



Trainable



Pretrained




Vision-and-language Representation learning

Pretrained





Trainable



Vision-to-language Generative learning


Pretrained






Vision-and-language


Representation learning



Vision-to-language
Generative learning



讓模型看圖說故事 (Image Captioning)



1. 影像預處理 (Processor)

原始圖片被標準化為張量 (Tensor):
`torch.Size([1, 3, 224, 224])`



2. 文字分詞 (Tokenizer)

GPT2TokenizerFast 將提示詞轉為 ID，
並處理字首空格 (如 G)。



3. 生成對話 (Generation)

BLIP-2 融合視覺張量與文字 ID，透過自迴
歸產出最終的自然語言序列。



兩大技術路徑總結：CLIP vs. BLIP-2

	CLIP (對齊派)	BLIP-2 (生成派)
核心目標	計算圖文相似度 (Similarity matching)	看圖推理與對話生成 (Visual Reasoning)
架構組成	Text Encoder + Image Encoder (平行雙生)	ViT + Q-Former + LLM (串接橋樑)
訓練重點	龐大的對比學習矩陣	訓練 Q-Former 產生 Soft Prompts
典型應用	以圖搜圖、零樣本分類	視覺問答 (VQA)、圖片自動標註



ai-twinkle/LLM-Book-Club



第三部分（Part III） 的訓練與微調



在多模態架構的資料流中，關於模型的「接收能力」與「生成能力」之關係，下列敘述何者最正確？

- A. 一個模型能夠接收某種模態（如視覺影像），並不代表它必須有能力生成該種模態。
- B. 多模態模型在架構設計上，其輸入端與輸出端的模態組合必須完全對稱。
- C. 只要模型被歸類為多模態模型，它就必須同時具備看圖（理解）與畫圖（生成）的能力。
- D. 如果一個多模態模型的核心強項是文字生成，那它在輸入端就無法接收影像特徵。

若有一張解析度為 $512 * 512$ 像素的圖片，在不採取任何特徵壓縮的情況下，直接將每個像素點拉平（Flatten）當作文字 Token 送進 Transformer 網路，其最主要的技術瓶頸是什麼？

- A. 自注意力機制的計算複雜度隨序列長度呈二次方 ($O(N^2)$) 速度暴增，會導致 VRAM 爆炸。
- B. 一維長向量會讓圖片丟失所有顏色通道 (RGB) 的特徵資訊。
- C. Transformer 隱藏層的維度完全無法與拉平後的像素序列長度進行矩陣相乘。
- D. 純文字的 Tokenizer 完全無法針對二維像素的數值生成對應的 Token ID。

根據經典論文《An Image is Worth 16x16 Words》，Vision Transformer (ViT) 主要是透過什麼方式來解決像素計算爆炸的困境？

- A. 將二維圖片切割成固定大小的局部區域「影像切塊 (Patches)」，以有效壓縮序列長度。
- B. 在送入模型前，將圖片的解析度強制降採樣 (Downsampling) 到 $16 * 16$ 像素。
- C. 捨棄 Transformer 的自注意力機制，改用傳統的卷積神經網路 (CNN) 來處理二維圖像。
- D. 僅提取圖片中心區域的特徵，直接忽略周圍邊緣的像素資訊。

在 Vision Transformer (ViT) 的視覺 Token 化管線 (Pipeline) 中，
將每個二維圖像區塊拉平 (Flatten) 後，下一步使用「線性投影
(Linear Projection)」的核心目的是什麼？

- A. 將拉平後的原始像素維度轉換並投影到符合 Transformer 隱藏層的固定維度空間。
- B. 為每個影像切塊注入空間順序關係，避免拼圖順序打亂。
- C. 凝聚、提煉整張圖片的全局視覺特徵 (Global Features)。
- D. 將 RGB 三個通道的顏色數值壓縮並轉換為單色灰階張量。

關於 CLIP (Contrastive Language-Image Pre-training) 架構的預訓練機制，下列敘述何者正確？

- A. 採用雙編碼器 (Dual Encoders) 架構，包含負責處理圖片的 Image Encoder 與負責處理自然語言描述的 Text Encoder。
- B. 高度依賴專業人工精準標註的乾巴巴單字標籤 (如人工標註這張圖叫貓、那張圖叫狗)。
- C. 在預訓練階段就融合了具備自然語言長文字生成大腦的凍結 LLM。
- D. 其主要訓練重點在於透過跨模態橋梁產生「軟視覺提示 (Soft Visual Prompts)」。

Bonus

Free NVIDIA RTX Pro 6000 Blackwell GPU <https://marimo.io/blog/reintroducing-molab>

marimo Your notebooks / Chapter 9 - Multimodal Large Language Models 4 CPU · 32 GiB · RTX Pro 6000 Share Duplicate

Clipping input data to the valid range for imshow with RGB data ([0..1] for floats or [0..255] for integers)

```
1 # Create the image embedding
2 image_embedding = model.get_image_features(processed_image).pooler_output
3 image_embedding.shape

torch.Size([1, 512])
```

```
1 # Normalize the embeddings
2 text_embedding_1 = text_embedding / text_embedding.norm(dim=-1, keepdim=True)
3 image_embedding_1 = image_embedding / image_embedding.norm(dim=-1, keepdim=True)
4 text_embedding_1 = text_embedding_1.detach().cpu().numpy()
5 # Calculate their similarity
6 image_embedding_1 = image_embedding_1.detach().cpu().numpy()
7 score = text_embedding_1 @ image_embedding_1.T
8 score

array([[0.33146894]], dtype=float32)
```

More Images

Errors Scratchpad Tracing Secrets Logs Terminal Snippets Kernel

NVIDIA-SMI 580.126.20			Driver Version: 580.126.20			CUDA Version: 13.0		
GPU	Name	Perf	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr.	ECC
Fan	Temp		Pwr:Usage/Cap		Memory-Usage	GPU-Util	Compute	MIG M.
0	NVIDIA RTX PRO 6000 Blac...	Off	N/A		Off			0
N/A	28C	P0	58W / 600W	3MiB /	97887MiB	0%	Default	Disabled





Q&A